

Application des réseaux de neurones à l'estimation des fréquences dominantes des tensions de lignes électriques HT

B. Boukhezzar, H. Siguerdidjane et F. Boudaoud
SUPELEC

3, rue Joliot Curie

F-91192 Gif-sur Yvette cedex

Email : boubekur.boukhezzar, Houria.siguerdidjane@supelec.fr

Abstract—Cet article propose une approche basée sur les réseaux de neurones artificiels pour l'estimation de fréquence à l'aide du perceptron multicouches (PMC). Deux types de réseaux ont été étudiés : Le réseau de Hopfield continu et le perceptron multicouches (PMC). Le réseau de Hopfield a déjà été utilisé pour l'estimation de la fréquence de signaux de courants et de tension, ce dernier présente un inconvénient de lenteur à l'encontre du perceptron multicouches, leurs principes de fonctionnement comme estimateurs sont exposés. Ces deux approches sont testées et comparées sur des signaux générés et sur des données issues du simulateur de réseaux EMTP. Les résultats de simulation montrent que l'utilisation du PMC pour l'estimation de fréquence conduit à de meilleurs résultats en termes de robustesse et de rapidité de calculs que le réseau de Hopfield continu.

I. INTRODUCTION

Depuis plusieurs décennies, l'estimation en temps réel des paramètres d'un signal sinusoïdal a reçu beaucoup d'intérêt dans plusieurs domaines comme le traitement du signal, l'analyse vibratoire, la géodésie et l'analyse des réseaux électriques.

Plusieurs méthodes ont été proposées pour cette fin, parmi lesquelles les méthodes de Prony [1], [2], la transformée de Fourier discrète (TFD), le filtrage de Kalman [3] et celle des moindres carrés [4].

Dans plusieurs applications, ces techniques présentent certains inconvénients : d'une part elles nécessitent un potentiel de calcul important, ce qui implique un temps relativement élevé pour la procédure d'estimation, d'autre part, dans leur version directe, ces méthodes ne sont pas parallélisables, et ne peuvent pas être par conséquent implémentées sur une architecture parallèle dans le but d'accélérer la vitesse de convergence des algorithmes d'estimation.

Durant les deux dernières décennies, une avancée importante a été réalisée dans le domaine des méthodes et architectures parallèles basées sur les réseaux de neurones artificiels (RNA). Ces derniers permettent un gain considérable de temps de calcul grâce à leur structure qui répartie les calculs entre plusieurs unités fondamentales.

Ces méthodes sont donc bien adaptées lorsque l'application considérée requiert des temps de calcul relativement courts.

On se propose, dans ce papier, d'estimer la fréquence dominante d'un signal en utilisant les réseaux de neurones artificiels. Ce signal est issu des bornes d'un disjoncteur lors de l'ouverture d'une ligne électrique HT compensée shunt, il est généré à l'aide du simulateur de réseaux EMTP/ATP.

Pour réaliser une manoeuvre contrôlée sur une ligne HT compensée shunt, il est montré que l'instant opportun de refermeture de la ligne doit être situé dans la fenêtre où le battement de tension est minimal. Ceci afin de ne pas engendrer de surtensions le long de la ligne [5].

En effet, l'amorçage électrique des contacts du disjoncteur provoque la propagation d'ondes qui risquent d'endommager les équipements connectés. Il est montré [6] que cet instant optimal de fermeture du dispositif de coupure est inversement proportionnel à la fréquence du signal de tension à ses bornes. Cet instant est d'autant plus précis que l'estimation de la fréquence dominante l'est, et doit se situer dans un intervalle de temps correspondant au battement minimum de la tension aux bornes du dispositif de coupure. Le but de la procédure d'estimation est donc de déduire de la fréquence estimée l'instant optimal pour effectuer une manoeuvre contrôlée (fermeture commandée) du dispositif de coupure.

A cause de leurs inconvénients déjà mentionnés, les méthodes citées plus haut ne permettent pas d'estimer assez rapidement la fréquence du signal quand le temps requis pour l'estimation est assez court afin de satisfaire une demande industrielle.

L'objectif de ce travail est de montrer que les RNA permettent une estimation rapide et robuste de la fréquence du signal.

Pour cette fin, deux méthodes d'estimation basées sur les RNA sont développées :

- 1) Le réseau de Hopfield continu qui a déjà été utilisé pour cette tâche [7]. Le principe est de combiner les RNA avec les techniques d'estimation paramétriques (moindres carrés, moindres modules, mini-max) durant la phase d'optimisation du critère par l'algorithme de descente du gradient, l'implémentation de cette procédure d'optimisation est effectuée sur un circuit neuronal analogique du type Hopfield.

- 2) Le perceptron multicouches (PMC), qui est un réseau de neurones non-récurrent qui approxime la correspondance entre l'espace des mesures (échantillons) et l'espace des paramètres. C'est cette correspondance qui constitue la procédure d'estimation.

II. RÉSEAUX DE HOPFIELD

Les réseaux de Hopfield sont des RNA récurrents complètement connectés. Ils furent d'abord développés sous forme de réseaux discrets, c'est à dire dont les neurones ont des sorties binaires (0 et 1, ou -1 et 1), ils sont alors utilisés comme mémoire autoassociative (adressable par son contenu) ou comme outil d'optimisation combinatoire (par exemple, la résolution du problème classique du voyageur de commerce) [8]. Si on remplace les neurones binaires par des neurones à sorties continues, les réseaux de Hopfield peuvent aussi être utilisés pour l'optimisation continue (fonctions à variables réelles).

Les méthodes d'estimation paramétrique sont basées sur la formulation à partir d'un modèle paramétrique du signal $y_m(t, \underline{\theta})$ et de ses échantillons \underline{Y} d'un critère $J(\underline{\theta})$, puis d'optimiser ce critère par rapport au vecteur des paramètres $\underline{\theta}$ pour trouver sa valeur optimale $\underline{\theta}^*$ tel que :

$$\underline{\theta}^* = \arg \min_{\underline{\theta} \in \mathbb{R}^q} \{J(\underline{\theta})\} \quad (1)$$

Le schéma ci-dessous montre la procédure d'estimation paramétrique




Fig. 1. Schéma de la procédure d'estimation paramétrique

Généralement, le critère choisi est une norme du vecteur d'erreur :

$$J_{L_p}(\underline{\theta}) = \left[\sum_{n=1}^N |(e_n(\underline{\theta}))^p| \right]^{\frac{1}{p}} = \|\underline{e}(\underline{\theta})\|_p \quad (2)$$

- Pour $p = 1$, le critère est celui des moindres modules (Norme L_1).
- Pour $p = 2$, le critère est celui des moindres carrés (Norme L_2).
- Pour $p = \infty$, le critère est celui du mini-max (Norme L_∞ ou de Chebyshev).

$$\text{avec } \underline{e}(\underline{\theta}) = \begin{pmatrix} e_1(\underline{\theta}) \\ \vdots \\ e_N(\underline{\theta}) \end{pmatrix} = \underline{Y} - \underline{Y}^m(\underline{\theta}) \quad (3)$$

$$\underline{Y}^m(\underline{\theta}) = \begin{pmatrix} y_1^m(\underline{\theta}) \\ \vdots \\ y_N^m(\underline{\theta}) \end{pmatrix} \quad (4)$$

$$\text{où } y_n^m(\underline{\theta}) = y^m(t, \underline{\theta})|_{t=nT} = y^m(nT, \underline{\theta}) \quad (5)$$

$$\underline{Y} = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix} \quad (6)$$

Les y_n sont les échantillons aux instants nT , T étant la période d'échantillonnage,

$$y_n = y(t)|_{t=nT} = y(nT) \quad (7)$$

Une fois le critère $E(\underline{\theta}) = J_{L_p}(\underline{\theta})$, choisit nous appliquons une descente continue du gradient pour l'optimisation de $E(\underline{\theta})$:

$$\frac{d\underline{\theta}}{dt} = -\frac{1}{\tau} \cdot \nabla E(\underline{\theta}) \quad (8)$$

Pour chaque valeur de p ($p = 1, 2$ et ∞), on aura, à partir de l'équation (8), un système d'équations différentielles dont la solution est une fonction du temps paramétrée par $\underline{\theta}$ qui converge vers la valeur optimale des paramètres $\underline{\theta}^*$ pour un temps infini [7].

Ces équations différentielles sont implémentées sur un réseau de Hopfield qui est un circuit parallèle analogique qui simule la descente du gradient de façon continue.

Si on suppose que le signal, dont on veut estimer la fréquence, est sinusoïdal

$$y^m(t, \underline{\theta}) = X_a \sin(\omega t) + X_b \cos(\omega t) \quad (9)$$

$$\underline{\theta} = (X_a, X_b, \omega)$$

l'équation (8) donne pour chaque norme un système d'équations différentielles.

D'après (3) l'erreur entre les échantillons et le modèle est égale au bruit pour la valeur optimale des paramètres, en effet :

$$y(t) = y_m(t) + e(t) \quad (10)$$

Selon l'hypothèse que l'on fait sur la nature du bruit, il conviendra d'utiliser le critère qui s'y adapte le mieux.

A. Critère MINI-MAX (L_∞ ou de Chebyshev)

Ce critère s'écrit aussi

$$J_{L_\infty} = \min_{1 \leq n \leq N} \max \{e_n(\underline{\theta})\} \quad (11)$$

On montre [9], [4] que ce critère est équivalent à celui du maximum de vraisemblance si le bruit $e(t)$ est uniforme

stationnaire.

Le système d'équations (8) s'écrit alors :

$$\begin{cases} \frac{dX_a}{dt} = \frac{1}{\tau} \sum_{n=1}^N S_n \text{sign}(e_i) \sin(n\omega t) \\ \frac{dX_b}{dt} = \frac{1}{\tau} \sum_{n=1}^N S_n \text{sign}(e_i) \cos(n\omega t) \\ \frac{d\omega}{dt} = \frac{1}{\tau} \sum_{n=1}^N S_n nT \text{sign}(e_i) [X_a \cos(n\omega t) - X_b \sin(n\omega t)] \end{cases} \quad (12)$$

$$\text{avec } S_n = \begin{cases} 1 & \text{si } e_n = \max_{1 \leq k \leq N} (|e_k|) \\ 0 & \text{sinon} \end{cases} \quad (13)$$

S_n est un circuit qui est appelé souvent "Winner Take-all circuit".

Le schéma du réseau de Hopfield estimateur implémenté sous MATLAB- SIMULINK[®].

B. Critère des moindres carrés (L_2)

Pour $p = 2$, le système (8) s'écrit

$$\begin{cases} \frac{dX_a}{dt} = \frac{1}{\tau} \sum_{n=1}^N \text{sign}(e_i) \sin(n\omega t) \\ \frac{dX_b}{dt} = \frac{1}{\tau} \sum_{n=1}^N \text{sign}(e_i) \cos(n\omega t) \\ \frac{d\omega}{dt} = \frac{1}{\tau} \sum_{n=1}^N nT \text{sign}(e_i) [X_a \cos(n\omega t) - X_b \sin(n\omega t)] \end{cases} \quad (14)$$

Ce système est obtenu à partir de (12) en posant $S_n=1$.

Minimiser $J_{L_2}(\theta)$ revient à estimer θ au sens du maximum de vraisemblance si le bruit est Gaussien stationnaire.

C. Critère des moindres modules (L_1)

Il suffit de poser $\text{sign}=1$ dans le système d'équations précédent pour aboutir aux équations correspondant à $p = 1$

$$\begin{cases} \frac{dX_a}{dt} = \frac{1}{\tau} \sum_{n=1}^N e_i \sin(n\omega t) \\ \frac{dX_b}{dt} = \frac{1}{\tau} \sum_{n=1}^N e_i \cos(n\omega t) \\ \frac{d\omega}{dt} = \frac{1}{\tau} \sum_{n=1}^N nT e_i [X_a \cos(n\omega t) - X_b \sin(n\omega t)] \end{cases} \quad (15)$$

L'équivalence entre ce critère et celui du maximum de vraisemblance est obtenue pour un bruit $e(t)$ Laplacien stationnaire.

C'est pendant l'étape d'optimisation du critère que les réseaux de Hopfield seront utilisés comme une structure parallèle d'optimisation [7]. On implémentera la descente du gradient

continue décrite dans (8) sur une structure parallèle qui est le réseau de Hopfield continu.

L'implémentation est réalisée uniquement en simulation et non sur circuits analogiques, les temps de calcul indiqués donc pour cette méthode sont les temps de simulations que l'ordinateur prend pour afficher les résultats.

III. PERCEPTRON MULTICOUCHES (PMC)

Les RNA sont communément utilisés pour faire la correspondance entre un vecteur d'entrée et un vecteur de sortie. Cette correspondance peut être utilisée pour la classification, l'autoassociation, la prédiction de séries temporelles ou plusieurs autres applications.

Il a été prouvé [10] que le perceptron multicouches (PMC) avec une seule couche cachée peut approximer toute fonction continue avec le degré de précision souhaité. Pour cela, le PMC est fréquemment utilisé comme approximateur universel de fonctions. Or un estimateur n'est qu'une correspondance entre l'espace des mesures et celui des paramètres [4], d'où l'idée d'utiliser le PMC comme approximateur de cette correspondance (Figure 2).




Fig. 2. Principe du PMC estimateur

Cette méthode est essentiellement différente de celle utilisée par les méthodes paramétriques basées sur un modèle du signal et utilisant toute l'information disponible sur les paramètres et les mesures dans le but de formuler un critère d'optimisation.

A. Caractéristiques du PMC estimateur

Le PMC estimateur est caractérisé par les propriétés suivantes :

- Il n'est pas nécessaire d'avoir un modèle du signal dont on veut estimer les paramètres ; il suffit d'avoir une base d'apprentissage formée de couples ayant pour composantes le vecteur d'échantillons du signal et les paramètres leurs correspondant ($\underline{Y}, \underline{\theta}_t$), cette base est utilisée pour entraîner le PMC.
- Après la phase d'entraînement ou d'apprentissage du PMC, ce dernier va constituer une correspondance qui associe les paramètres du signal à chaque vecteur d'échantillons. Contrairement aux méthodes itératives, la réponse est obtenue sans aucune itération, ceci les rend plus rapides et bien adaptés pour l'utilisation en temps réel.
- Si le réseau est entraîné en présence de bruit, il fera une estimation plus robuste des paramètres du signal à partir de données bruitées.

B. Description de la méthode

Le réseau utilisé est un PMC qui possède N entrées et une sortie. Les N entrées constituent le vecteur des échantillons présenté au réseau et la sortie correspond à la fréquence estimée du signal calculée par le RNA.

Dans le but de l'entraîner, on présente au réseau, pendant la phase d'apprentissage, un ensemble de couples (vecteurs d'échantillons, fréquence du signal) qui constituent la base d'apprentissage. Une fois la phase d'apprentissage terminée, on présente à l'entrée du réseau un vecteur d'échantillons, et le réseau entraîné estime les paramètres à sa sortie (propagation avant).

La procédure d'apprentissage est certainement longue, mais elle est effectuée une seule fois et hors-ligne (phase d'apprentissage). En temps réel, le PMC estimateur ne fait aucun calcul itératif. Le réseau de neurones est entraîné par l'algorithme de Levenberg-Madquart [11] qui minimise l'erreur quadratique totale entre les sorties et les sorties désirées.

Cependant, avant de présenter les données au réseau, pendant la phase d'apprentissage ou après, ces données sont normalisées. Pour cela, le RNA estimateur est précédé d'une unité de prétraitement. Dans cette partie, l'amplitude des échantillons est normalisée ainsi que la phase initiale en ne prenant les échantillons qu'à partir du début du premier lobe positif.

Le schéma du PMC estimateur est donné ci-dessous :




Fig. 3. Perceptron Multicouches estimateur

Cette opération de prétraitement permet d'obtenir des échantillons qui seront présentés au réseau avec une phase initiale et une amplitude du même ordre de grandeur. Ceci réduit l'espace des observations à un sous espace avec moins de paramètres.

Nous savons que plus l'espace de recherche est grand et complexe, plus la procédure d'estimation sera difficile, d'où l'intérêt de faire un prétraitement des données d'entrée pour réduire le nombre de paramètres et avoir un espace de recherche moins complexe.

IV. RÉSULTATS DE SIMULATION

Dans le but de vérifier les performances de chaque type de réseau, nous avons testé les deux méthodes, tout d'abord sur un signal généré bruité, puis sur des signaux issus du simulateur de réseaux EMTF.

Les résultats de simulation confirment bien que l'utilisation du PMC estimateur donne de meilleurs résultats en termes de robustesse et de rapidité pour l'estimation.

Le comportement du réseau de Hopfield estimateur est décrit par les systèmes d'équations différentielles (12), (14) et (15) qui peuvent être implémentées sur un circuit neuronal analogique. Ce système est résolu numériquement pour les trois cas ($p = 1, 2$ et ∞).

L'estimation de fréquence par le réseau de Hopfield continu est testée en simulation sur un signal sinusoïdal généré contaminé par un bruit normal $\mathcal{N}(0, \sigma^2)$ additif.

$$x(t) = 80 \sin(\omega t) - 50 \cos(\omega t) + b(t) \quad (16)$$

$$\omega = 80\pi$$

Le RSB est fixé à 15 dB

$$RSB_{dB} = 10 \log \left[\frac{Am^2}{\sigma^2} \right] \quad (17)$$

où $Am = \sqrt{X_a^2 + X_b^2}$ amplitude du signal
et σ^2 variance du bruit

Les résultats de simulation montrent le comportement d'un circuit neuronal idéal de type Hopfield pour l'estimation de la fréquence $f = \frac{\omega}{2\pi}$ et de X_a et X_b .

Ils sont respectivement représentés sur les figures (4) et (5).




Fig. 4. Fréquence estimée par le réseau de Hopfield




Fig. 5. Amplitudes estimées par le réseau de Hopfield

La période d'échantillonnage choisie pour le signal (16) est $T_e = 0.5$ ms. Pour les constantes d'intégration des équations différentielles nous avons pris $\tau = 2.10^{-8}$.

La figure 4 montre que le circuit neuronal converge vers la fréquence recherchée très rapidement (micro secondes) avec une très faible erreur, ceci est réalisé pour un comportement idéal des composants du circuit neuronal (intégrateurs, additionneurs, gains) ce qui n'est pas le cas en pratique vu le comportement non linéaire des composants (saturations, temps morts, hysteresis, ...). On observe aussi que c'est avec le critère des moindres carrés (L_2) que l'on obtient les meilleurs résultats. Ceci est justifié par la nature du bruit, nous avons en effet mentionné que ce critère est équivalent à celui du maximum de vraisemblance dans le cas d'un bruit Gaussien.

Cependant le temps de simulation est assez élevé, il est de l'ordre d'une dizaine de secondes, ce qui rend ce réseau peu attirant s'il n'est pas implémenté de façon matérielle pour l'estimation de fréquence. La figure 6 montre l'erreur d'estimation par le réseau de Hopfield dans le cas du critère L_2 sur une séquence de signaux de test bruités correspondant au signal de l'équation (16) avec une fréquence choisie aléatoirement et variant entre 35 Hz et 55 Hz.




Fig. 6. Erreurs absolues sur les fréquences estimées par le réseau de Hopfield (cas L_2) sur les signaux générés

Le PMC estimateur est testé avec le même ensemble de signaux de l'équation (16) correspondant à la même séquence de fréquences aléatoirement choisie et la même période d'échantillonnage f_e que le réseau de Hopfield continu.

Nous avons d'abord entraîné le réseau sur une base d'apprentissage que l'on a construite. Cette base est construite en faisant varier aléatoirement la fréquence f entre 35 Hz et 55 Hz, nous prenons $N = 20$ échantillons pour chaque fréquence choisie pour faire partie de la base d'apprentissage. Chaque couple formé d'un vecteur de N échantillons et de la fréquence lui correspondant (\underline{Y} , f_t) est un patron dans cette base.

Cette base subit comme nous l'avons mentionné plus haut un prétraitement avant d'être présenté au réseau de neurones proprement dit. L'algorithme de Levenberg-Marquart est alors utilisé pour entraîner le PMC estimateur avec un seuil d'arrêt de 10^{-2} pour l'erreur globale.

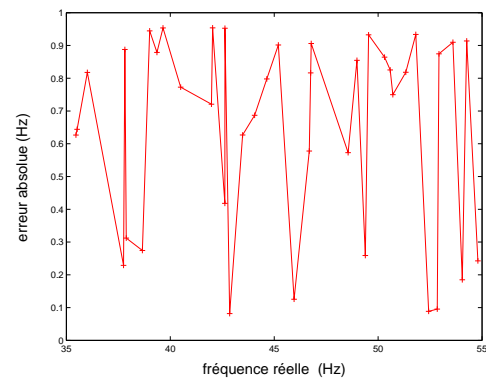


Fig. 7. Erreurs absolues sur les fréquences estimées par le PMC sur les signaux générés

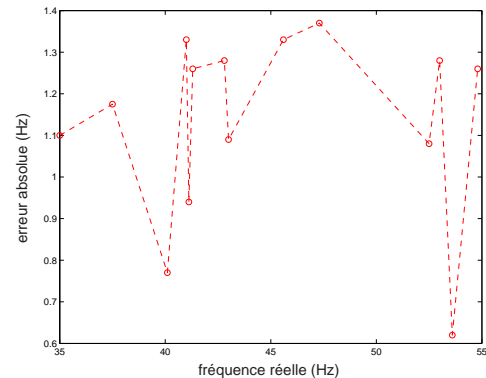


Fig. 8. Erreurs absolues sur les fréquences estimées par le PMC sur les signaux EMTP

Cet algorithme recherche la configuration optimale des poids du réseau qui minimise l'erreur quadratique globale entre les sorties du réseau qui sont les fréquences estimées et les fréquences réelles qui sont les cibles recherchées.

Le réseau utilisé possède N entrées qui sont les échantillons qui ont subi un prétraitement, une couche cachée de 20 neurones sigmoïdes, et une seule sortie de fonction d'activation linéaire. La convergence de l'algorithme d'apprentissage est obtenue après 10 itérations.

La figure 7 montre l'erreur d'estimation entre la fréquence réelle et estimée. On peut observer que même si les fréquences ne sont pas apprises pendant la phase d'entraînement, le PMC estimateur les retrouve avec une erreur inférieure à 1 Hz. Ceci prouve la robustesse de cet estimateur ainsi que sa capacité de généralisation.

Le PMC estimateur a été aussi testé avec des signaux issus du simulateur de réseaux EMTP pour l'estimation de leur fréquence. Les paramètres physiques de la ligne simulée sont les suivants :

- Paramètres de la source :
 - Tension nominale du réseau : 500 kV
 - Fréquence nominale du réseau : 50 Hz
 - Impédance de la source : $Z_{cc} = 0.5 + j25.1 \Omega$
 - Longueur : 400 km

- Paramètres linéiques de la séquence homopolaire :
 - $r_0 = 0.075 \Omega/\text{km}$
 - $l_0 = 2.864 \text{ mH/km}$
 - $c_0 = 6 \text{ nF/km}$
- Paramètres linéiques de la séquence directe :
 - $r_d = 0.025 \Omega/\text{km}$
 - $l_0 = 0.954 \text{ mH/km}$
 - $c_0 = 14 \text{ nF/km}$

La procédure d'entraînement reste la même sauf que la base d'apprentissage fournie au PMC est formée de données issues du simulateur avec leurs fréquences correspondantes.

Pour tester le réseau, on utilise des signaux n'appartenant pas à la base (non appris) comme entrées. l'erreur est ici de l'ordre de 3% (Figure 8) sur la même plage de fréquence. Le temps d'estimation est très court, il est de l'ordre d'une dizaine de millisecondes.

Ces résultats prouvent donc que le PMC estime la fréquence plus rapidement et d'une façon plus robuste que le réseau de Hopfield continu.

V. CONCLUSION

Les simulations ont montré que l'utilisation du réseau de Hopfield en tant qu'estimateur nécessite un temps de calcul important, ceci est dû au fait que son implémentation revient à résoudre numériquement un système d'équations différentielles non linéaires, cette procédure est exigeante en volume de calcul. En revanche, pour le perceptron multicouches, une fois l'apprentissage effectué, l'estimation se fait de façon non récurrente d'où la rapidité de cette approche. La capacité de généralisation du PMC permet d'estimer des fréquences de signaux qui n'ont pas été appris, la précision est de l'ordre de 3% pour les signaux EMTP, de plus la structure répartie du PMC lui confère une meilleure robustesse au bruit.

Ceci le rend plus attirant que les réseaux de Hopfield pour l'estimation de fréquence en temps réel dans des applications industrielles, surtout quand le temps d'estimation est assez court.

REFERENCES

- [1] J. Hauer, C. Demeure, and L. Scharf, "Initial results in prony analysis of power system response signal," *IEEE Transaction on power systems*, vol. 9, no. 2, pp. 612–618, 1994.
- [2] F. Boudaoud, H. Siguerdidjane, and P. Bastard, "Marix pencil : A novel approach for fast shunt compensated line controlled switching," *ECC*, vol. 1- 4, Sep 2003. Cambridge.
- [3] A. Girgis and R. Brown, "Application of kalman filtering in computer relaying," *IEEE transaction on power apparatus and systems*, pp. 3387–3395, 1981.
- [4] H. L. V. Trees, *Detection, Estimation, and Modulation Theory, Part I*. John Wiley & Sons, 1971.
- [5] F. Boudaoud, *Manœuvre contrôlée sur lignes de transport HT à vide*. PhD thesis, Université de Paris-Sud, Mai 2003.
- [6] U. Samitz, F. Boudaoud, H. Siguerdidjane, P. Bastard, J. P. Dupraz, M. Collet, J. Martin, and T. Jung, "On controlled switching of high voltage unloaded transmission lines," *CIGRE*, pp. 13–206, Aug 2002. Paris.
- [7] A. Cichocki and T. Lobos, "Artificial neural networks for real-time estimation of basic waveforms of voltages and currents," *IEEE Transactions on Power Systems*, vol. 9, pp. 612–618, May 1994.
- [8] S. Aiyer, M. Niranjan, and F. Fallside, "A theoretical investigation into the performance of the hopfield," *IEEE Transactions on neural networks*, vol. 1, no. 2, pp. 204–215, 1990.
- [9] E. Walter and L. Pronzato, *Identification de modèles paramétriques à partir de données expérimentales*. Paris : Masson, 1994.
- [10] K. Hornick, M. Stinchcombe, and H. White, "Multilayer feedforward neural networks are universal approximators," *Neural Networks*, vol. 2, pp. 359–366, 1989.
- [11] M. Hogan and M. Menhaj, "Training feedforward networks with the marquardt algorithm," *IEEE Transactions on Neural Networks*, vol. 5, no. 6, pp. 989–993, 1994.